

دانشگاه صنعتی امیر کبیر
(پلی تکنیک تهران)

دانشکده ریاضیات و علوم کامپیووتر

تحلیل قابلیت های خوشه بندی NMF

پروژه پایانی درس جبر خطی عددی

آرمان صالحی

استاد درس:

دکتر مهدی دهقان

۱۴۰۴ زمستان



چکیده

چکیده در این پژوهش، به بررسی و پیاده‌سازی الگوریتم تجزیه نامنفی ماتریس (NMF) به عنوان یک روش قدرتمند برای کاهش ابعاد و خوشبندی داده‌ها پرداخته شده است. هدف اصلی، اعمال این الگوریتم بر روی مجموعه داده ارقام دست‌نویس (MNIST) و استخراج الگوهای پایه سازنده این ارقام است. برخلاف روش‌های سنتی مانند K-means که بر اساس میانگین‌گیری از کل داده عمل می‌کنند، NMF با تجزیه داده‌ها به مولفه‌های نامنفی، رویکردی "بخش محور" ارائه می‌دهد که تفسیرپذیری بالایی دارد. در بخش عملی، نتایج حاصل از NMF با الگوریتم K-means مقایسه شده است. نتایج بصری نشان می‌دهد که پایه‌های به دست آمده از NMF شبیه به اجزاء تشکیل‌دهنده اعداد (مانند خطوط و کمان‌ها) هستند، در حالی که مراکز خوشبندی K-means شبیه به میانگین محو شده اعداد کامل می‌باشند. همچنین دقت خوشبندی هر دو روش به صورت کمی محاسبه و مقایسه گردید.

کلمات کلیدی: جبر خطی عددی، تجزیه نامنفی ماتریس (NMF)، خوشبندی K-means، داده‌کاوی،

MNIST مجموعه داده



فهرست مطالب

فصل اول: مقدمه و کلیات	۴
۱-۱ مقدمه	۴
۱-۲ بیان مسئله	۴
۱-۳ معرفی روش های مورد استفاده	۵
۱-۴ ساختار گزارش	۶
فصل دوم: مبانی نظری و پیشینه تحقیق	۶
۲-۱ مقدمه	۶
۲-۲ تجزیه نامنفی ماتریس (NMF)	۶
۲-۳ الگوریتم خوشبندی K-means	۹
۲-۴ مقایسه نظری: جزء نگر در برابر کل نگر	۱۰
فصل سوم: پیاده سازی و تحلیل نتایج	۱۱
۳-۱ معرفی مجموعه داده MNIST	۱۱
۳-۲ ابزارها و محیط پیاده سازی	۱۱
۳-۳ نتایج تجزیه نامنفی ماتریس (NMF)	۱۲
۳-۴ نتایج خوشبندی K-means	۱۳
۳-۵ مقایسه کمی (دقت خوشبندی)	۱۴
فصل چهارم: نتیجه گیری و پیشنهادات	۱۵
۴-۱ نتیجه گیری	۱۵
۴-۲ پیشنهادات برای کارهای آتی	۱۶
مراجع	۱۷
پیوست	۱۸



فصل اول: مقدمه و کلیات

۱-۱ مقدمه

در عصر حاضر، با رشد روزافزون داده‌های دیجیتال، نیاز به روش‌های خودکار برای تحلیل و استخراج اطلاعات از این داده‌ها بیش از پیش احساس می‌شود. یکی از حوزه‌های اصلی در هوش مصنوعی و یادگیری ماشین، یادگیری ناظارت‌نشده (Unsupervised Learning) است که در آن الگوریتم بدون داشتن برچسب‌های از پیش تعیین‌شده، سعی در کشف ساختارهای پنهان و الگوهای موجود در داده‌ها دارد.

خوشبندی (Clustering) به عنوان یکی از مهم‌ترین تکنیک‌های یادگیری ناظارت‌نشده، فرآیندی است که در آن داده‌ها به گروه‌هایی تقسیم می‌شوند که اعضای هر گروه بیشترین شباهت را به یکدیگر و بیشترین تفاوت را با اعضای سایر گروه‌ها داشته باشند. این تکنیک در کاربردهای متنوعی از جمله پردازش تصویر، فشرده‌سازی داده‌ها، و تشخیص الگو کاربرد دارد.

در این پژوهش، تمرکز ما بر روی تحلیل و خوشبندی تصاویر ارقام دست‌نویس است. چالش اصلی در پردازش این تصاویر، ابعاد بالای داده‌ها و تغییرات زیاد در نحوه نوشتن ارقام توسط افراد مختلف است. برای غلبه بر این چالش، از روش‌های کاهش ابعاد و تجزیه ماتریس استفاده می‌شود.

۱-۲ بیان مسئله

مسئله‌ی مورد بررسی در این پژوهش، خوشبندی تصاویر مجموعه داده MNIST است. این مجموعه داده شامل تصاویر سیاه و سفید از ارقام دست‌نویس (۰ تا ۹) است که هر کدام در یک شبکه پیکسلی مشخص ۲۸ در ۲۸ پیکسل) قرار دارند.

هدف اصلی این است که با استفاده از الگوریتم‌های جبر خطی عددی، این تصاویر را پردازش کرده و الگوریتم بتواند بدون دانستن برچسب واقعی تصاویر (یعنی بدون اینکه بداند کدام عکس عدد ۵ است یا ۷)، آنها را بر اساس ویژگی‌های ظاهری دسته‌بندی کند. همچنین، استخراج ویژگی‌های پایه‌ای که این ارقام را تشکیل می‌دهند (مانند خطوط عمودی، افقی و حلقه‌ها) بخش مهمی از این پژوهش است.



۳-۱ معرفی روش های مورد استفاده

برای انجام این پروژه، از دو رویکرد متفاوت استفاده و نتایج آنها مقایسه خواهد شد:

۱. تجزیه نامنفی ماتریس (NMF): این روش یکی از تکنیک‌های قدرتمند در جبر خطی است که ماتریس داده‌ها را به دو ماتریس با درایه‌های نامنفی تجزیه می‌کند. ویژگی منحصر به فرد NMF این است که به دلیل قید نامنفی بودن، اجزای سازنده داده‌ها را به صورت «بخش محور (Parts-based)» «یاد می‌گیرد. این یعنی NMF سعی می‌کند تصاویر را به عنوان ترکیبی از اجزای کوچکتر (مانند تکه‌های قلم) بازسازی کند.
۲. الگوریتم K-means: این الگوریتم یکی از کلاسیک‌ترین روش‌های خوشبندی است که بر اساس فاصله اقلیدسی و میانگین‌گیری عمل می‌کند. برخلاف NMF، روش K-means معمولاً رویکردی «کل محور» دارد و مراکز خوشبدها در آن شبیه به میانگین کلی تصاویر یک دسته هستند.



شکل ۱-۱: نمونه‌هایی از تنوع دستخط‌ها در مجموعه داده MNIST



۴-۱ ساختار گزارش

این گزارش در چهار فصل تدوین شده است. پس از این مقدمه، در فصل دوم به مبانی نظری و ریاضیاتی تجزیه NMF و الگوریتم K-means خواهیم پرداخت. در فصل سوم، پیاده‌سازی عملی الگوریتم‌ها بر روی داده‌های MNIST شرح داده شده و نتایج کمی و کیفی (شامل تصاویر پایه‌ها و دقت خوشبندی) تحلیل می‌شوند. در نهایت، در فصل چهارم نتیجه‌گیری کلی پروژه و پیشنهادات ارائه خواهد شد.

فصل دوم: مبانی نظری و پیشینه تحقیق

۲-۱ مقدمه

در این فصل به بررسی دقیق ریاضیاتی الگوریتم‌های مورد استفاده در پروژه می‌پردازیم. ابتدا الگوریتم تجزیه نامنفی ماتریس (NMF) و فرمولبندی آن در جبر خطی را تشریح کرده و سپس به الگوریتم خوشبندی K-means خواهیم پرداخت. در نهایت، تفاوت بین این دو روش در نحوه نمایش داده‌ها بررسی می‌شود.

۲-۲ تجزیه نامنفی ماتریس (NMF)

تجزیه نامنفی ماتریس (Non-negative Matrix Factorization) گروهی از الگوریتم‌ها در تحلیل چندمتغیره و جبر خطی است که در آن یک ماتریس X به دو ماتریس H و W تجزیه می‌شود، با این قید مهم که تمام درایه‌های این سه ماتریس باید نامنفی (بزرگتر یا مساوی صفر) باشند.



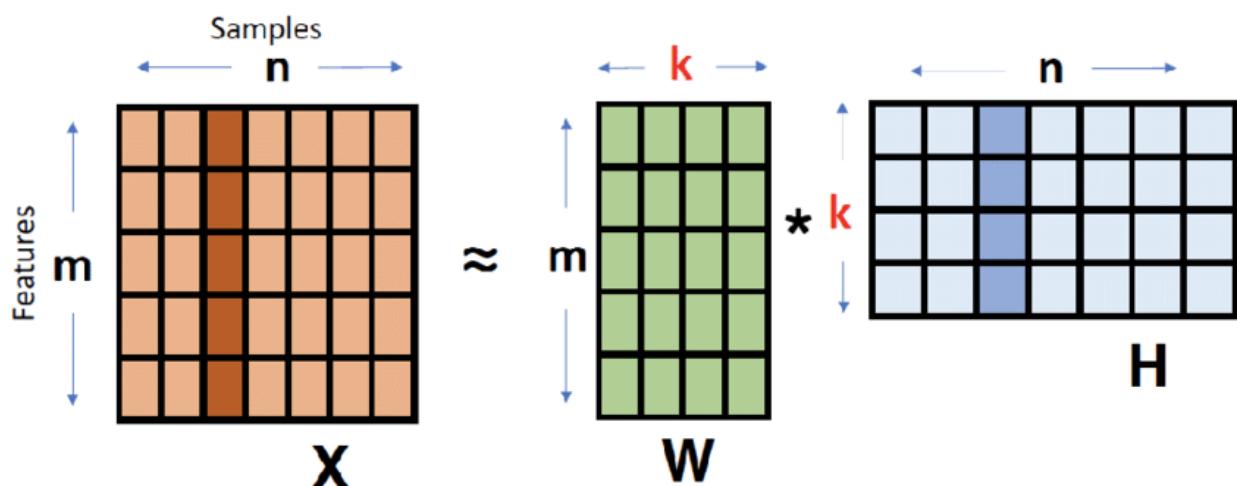
۲-۲-۱ فرمولبندی ریاضی

فرض کنید مجموعه داده‌های ما به صورت ماتریس X با ابعاد $n \times m$ باشد که در آن n تعداد ویژگی‌ها (پیکسل‌ها) و m تعداد نمونه‌ها (تصاویر) است. هدف NMF یافتن دو ماتریس H و W است بطوریکه:

$$X \approx WH$$

که در آن:

- ماتریس $X \in \mathbb{R}^{n \times m}$: ماتریس داده‌های ورودی (شامل درایه‌های نامنفی).
- ماتریس $W \in \mathbb{R}^{n \times r}$: ماتریس ویژگی‌های پایه. ستون‌های این ماتریس همان «الگوهای پایه» یا اجزای سازنده تصاویر هستند.
- ماتریس $H \in \mathbb{R}^{r \times m}$: ماتریس ضرایب یا کدگذاری. هر ستون نشان می‌دهد که چه ترکیبی از پایه‌ها برای ساختن تصویر اصلی نیاز است.
- پارامتر r : رتبه تجزیه یا تعداد مولفه‌ها که معمولاً بسیار کوچکتر از n و m انتخاب می‌شود.





۲-۲-۲ قید نامنفی بودن و تفسیرپذیری

تفاوت اصلی NMF با روش‌هایی مانند PCA (تحلیل مولفه‌های اصلی) در قید زیر است:

$$X_{ij} \geq 0, \quad W_{ik} \geq 0, \quad H_{kj} \geq 0$$

این قید باعث می‌شود که بازسازی داده‌ها تنها از طریق جمع مولفه‌ها صورت گیرد و هیچ تفریق کردنی وجود نداشته باشد. به عبارت دیگر، یک تصویر به صورت ترکیبی از روی هم قرار گرفتن چندین لایه (پایه) ساخته می‌شود. این ویژگی باعث می‌شود پایه‌های به دست آمده W شبیه به اجزای معنادار تصویر (مانند خطوط، گوشه‌ها و منحنی‌ها در ارقام) باشند.

۲-۲-۳ تابع هزینه و بهروزرسانی

برای پیدا کردن بهترین ماتریس‌های W و H ، باید فاصله بین ماتریس اصلی X و ماتریس بازسازی شده WH را کمینه کنیم. رایج‌ترین تابع هزینه، نرم فروینیوس است:

$$\min_{W,H} \frac{1}{2} \| |X - WH| \|_F^2$$

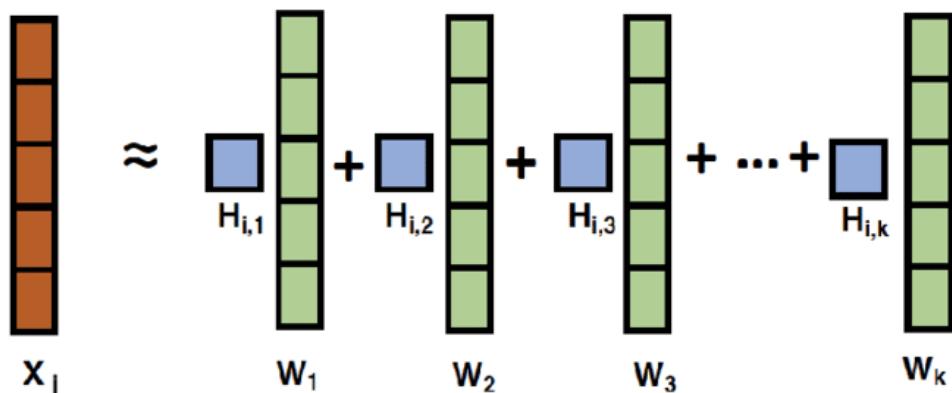
$$\text{subject to } W, H \geq 0$$

از آنجا که این تابع نسبت به هر دو متغیر W و H محدب نیست، راه حل بسته ریاضی ندارد. برای حل آن معمولاً از روش‌های تکرارشی (Iterative) استفاده می‌شود. یکی از معروف‌ترین الگوریتم‌ها، «قوانین بهروزرسانی ضربی‌پیشنهاد شده توسط لی و سونگ» (Lee & Seung) است:

$$H_{kj} \leftarrow H_{kj} \frac{(W^T X)_{kj}}{(W^T W H)_{kj}}$$

$$W_{ik} \leftarrow W_{ik} \frac{(X H^T)_{ik}}{(W H H^T)_{ik}}$$

این بهروزرسانی‌ها تضمین می‌کنند که اگر ماتریس‌های اولیه نامنفی باشند، در تمام تکرارها نامنفی باقی مانند و تابع هزینه به صورت یکنواخت کاهش یابد.



۲-۳ الگوریتم خوشبندی

الگوریتم K-means یکی از ساده‌ترین و پرکاربردترین الگوریتم‌های خوشبندی است که هدف آن تقسیم m داده ورودی به k خوشبندی مجزا است، به طوری که واریانس درون هر خوشبندی کمینه شود.

۲-۳-۱ تابع هدف

این الگوریتم سعی می‌کند تابع هدف J که مجموع مربعات فاصله هر نقطه تا مرکز خوشبندی اش است، کمینه کند:

$$J = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

که در آن:

- k : تعداد خوشبندیها

- C_j : مجموعه نقاط متعلق به خوشبندی j

- μ_j : میانگین نقاط خوشبندی j

- $\|\cdot\|$: فاصله اقلیدسی استاندارد



در زمینه پردازش تصویر، مراکز خوشبندی (μ) نماینده «میانگین کلی» تصاویری هستند که در آن خوشبندی قرار گرفته‌اند. برخلاف NMF که تصویر را از ترکیب اجزای می‌سازد، K-means برای هر تصویر فقط یک مرکز (نماینده) در نظر می‌گیرد.

۴-۲ مقایسه نظری: جزء‌نگر در برابر کل نگر

مهم‌ترین تفاوت نظری بین NMF و K-means در نحوه نمایش اطلاعات است:

۱. رویکرد K-means (کل نگر): این روش از نوع Vector Quantization است. هر داده تنها با یک بردار مرجع (مرکز خوشبندی) تقریب زده می‌شود. بنابراین مراکز خوشبندی‌ها باید شبیه به یک نسخه کامل (اما میانگین‌گیری شده) از داده‌ها باشند.

۲. رویکرد NMF (جزء‌نگر): این روش داده را به صورت ترکیب خطی چندین بردار پایه تقریب می‌زند ($\sum w_i h_i \approx x$). چون ضرایب منفی مجاز نیستند، الگوریتم مجبور است ویژگی‌هایی را یاد بگیرد که «اجزای سازنده» داده‌ها باشند. این تفاوت باعث می‌شود که در کاربرد تشخیص ارقام، NMF پایه‌هایی شبیه به قلم‌موی نوشتن تولید کند، در حالی که K-means تصاویری شبیه به ارقام کامل اما مات تولید می‌کند.



مقایسه بصری پایه‌های استخراج شده. (چپ) پایه‌های PCA که به صورت چهره‌های کامل اما محو هستند. (راست) پایه‌های NMF که به صورت اجزای موضعی و تفکیک شده مثل بینی یا ابرو ظاهر شده‌اند.



فصل سوم: پیاده‌سازی و تحلیل نتایج

۱-۳ معرفی مجموعه داده MNIST

در این پژوهه از مجموعه داده استاندارد MNIST استفاده شده است. این مجموعه شامل ۷۰,۰۰۰ تصویر از ارقام دستنویس (۰ تا ۹) است که به طور گستردگی برای آموزش و تست سیستم‌های یادگیری ماشین استفاده می‌شود.

- تعداد نمونه‌ها: ۷۰,۰۰۰ تصویر (۶۰,۰۰۰ داده آموزش و ۱۰,۰۰۰ داده تست).
- ابعاد تصاویر: هر تصویر سیاه و سفید و دارای ابعاد ۲۸ در ۲۸ پیکسل است.
- فرمت داده: هر تصویر به صورت یک بردار مسطح شده با طول ۷۸۴ (28×28) نمایش داده می‌شود تا بتواند به عنوان ورودی به الگوریتم‌های ماتریسی داده شود.

۲-۳ ابزارها و محیط پیاده‌سازی

برای پیاده‌سازی این پژوهه از زبان برنامه‌نویسی Python استفاده شده است. جهت مدیریت وابستگی‌ها و محیط مجازی، از ابزار Poetry استفاده گردید تا تکرار پذیری نتایج تضمین شود. کتابخانه‌های اصلی مورد استفاده عبارتند از:

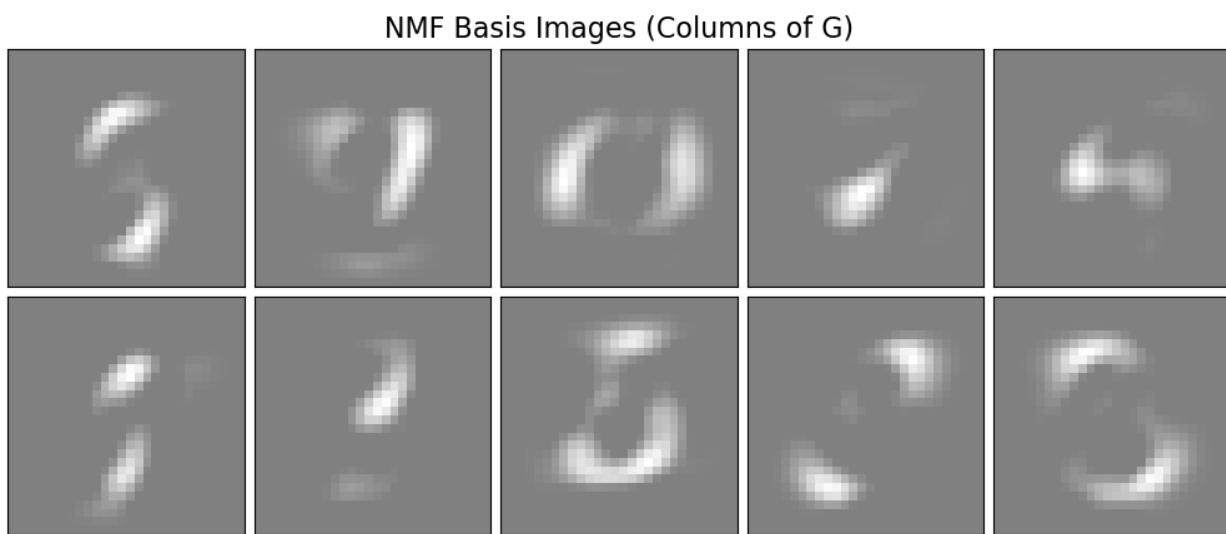
۱. Scikit-learn: برای اجرای الگوریتم‌های NMF و K-means و محاسبه معیارهای ارزیابی.
۲. NumPy: برای عملیات ماتریسی و برداری.
۳. Matplotlib: برای رسم نمودارها و نمایش تصاویر خروجی.



۳-۳ نتایج تجزیه فاصله‌نامنفی ماتریس (NMF)

در این بخش، الگوریتم NMF با تعداد مولفه‌های $10 = n_{components}$ بر روی کل داده‌های نرمال‌سازی شده اجرا گردید. هدف از این کار، یافتن ۱۰ الگوی پایه‌ای است که تمامی ارقام دیگر از ترکیب آن‌ها ساخته می‌شوند.

شكل زیر خروجی حاصل از ماتریس H (تصاویر پایه) را نشان می‌دهد:



شکل ۳-۱: تصاویر پایه استخراج شده توسط الگوریتم NMF

تحلیل کیفی نتایج NMF

همان‌طور که در شکل ۳-۱ مشاهده می‌شود، پایه‌های به دست آمده شبیه به ارقام کامل نیستند، بلکه شبیه به اجزای سازنده ارقام هستند. برای مثال:

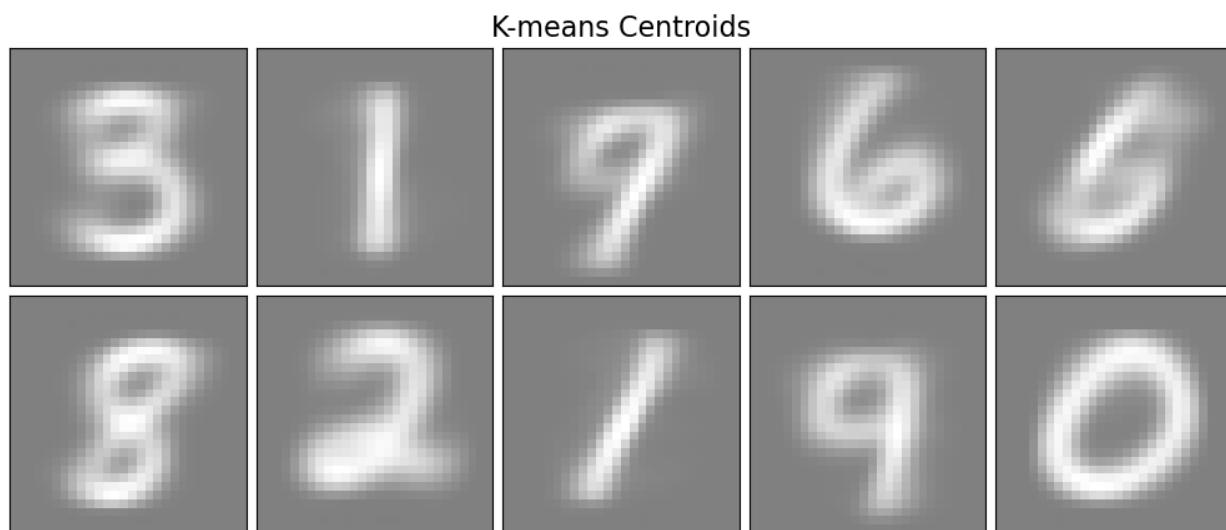
- برخی پایه‌ها تنها یک خط کج یا افقی را نشان می‌دهند.
- برخی دیگر شبیه به کمان‌ها یا حلقه‌هایی هستند که در اعداد ۸، ۰ یا ۹ دیده می‌شوند.

این نتیجه دقیقاً خاصیت Parts-based NMF را تایید می‌کند. الگوریتم یاد گرفته است که برای ساختن یک عدد، باید این اجزا را با هم جمع کند.



۴-۳ نتایج خوشبندی K-means

برای مقایسه، الگوریتم K-means نیز با ۱۰ خوشبندی همان داده ها اجرا شد. مراکز خوشبندی های به دست آمده در شکل زیر نمایش داده شده اند:



شکل ۳-۲: مراکز خوشبندی حاصل از الگوریتم K-means

تحلیل کیفی نتایج K-means

در شکل ۳-۲ مشاهده می شود که مراکز خوشبندی ها شبیه به میانگین محو شده ارقام کامل هستند. برخلاف NMF، در اینجا هر تصویر نماینده یک عدد کامل (مثل میانگین تمام صفرهای موجود در دیتابست) است. این تفاوت نشان دهنده ماهیت کل نگر روش K-means است.



۳-۵ مقایسه کمی (دقت خوشبندی)

علاوه بر تحلیل بصری، دقت هر دو روش در دسته‌بندی داده‌های بدون برچسب اندازه‌گیری شد. از آنجا که خوشبندی یک روش ناظر نشده است، برای محاسبه دقت از الگوریتم تطبیق اریب (Hungarian) استفاده شد تا بهترین تناظر بین خوشها و برچسب‌های واقعی پیدا شود.

نتایج حاصل از اجرا به شرح زیر است:

الگوریتم	دقت
NMF	0.3418
K-means	0.5323

همان‌طور که مشاهده می‌شود، روش K-means در این آزمایش عملکرد بهتری نسبت به روش دیگر داشته است. البته مزیت اصلی NMF در اینجا صرفاً دقت نیست، بلکه قابلیت تفسیرپذیری بالای ویژگی‌های استخراج شده است.



فصل چهارم: نتیجه‌گیری و پیشنهادات

۱-۴ نتیجه‌گیری

در این پژوهش، قابلیت‌های الگوریتم تجزیه نامنفی ماتریس (NMF) در استخراج ویژگی و خوشبندی تصاویر ارقام دست‌نویس (MNIST) مورد بررسی قرار گرفت و عملکرد آن با روش کلاسیک K-means مقایسه شد. نتایج به دست آمده نشان می‌دهد که:

۱. نمایش بخش محور: مهم‌ترین ویژگی NMF، توانایی آن در تجزیه تصاویر به «اجزای سازنده» است. تصاویر پایه استخراج شده توسط NMF (مانند خطوط و کمان‌ها) نشان دادند که این الگوریتم به درستی ساختار درونی داده‌ها را یاد گرفته است. این ویژگی باعث می‌شود NMF در کاربردهایی که تفسیرپذیری مدل اهمیت دارد (مانند تشخیص چهره یا تحلیل متن)، برتری قابل توجهی داشته باشد.
۲. تفاوت با K-means: در مقابل، الگوریتم K-means رویکردی «کل نگر» داشت و مراکز خوشبها را به صورت میانگین کلی ارقام نشان داد. اگرچه K-means از نظر محاسباتی سریع است، اما فقد قابلیت تفکیک اجزای داده‌ها می‌باشد.
۳. دقت خوشبندی: از نظر کمی، هر دو الگوریتم توانستند با دقیقی قابل قبول (با توجه به ماهیت نظارت‌نشده مسئله) ارقام را دسته‌بندی کنند. این نشان می‌دهد که فضای ویژگی‌های کاهش‌یافته توسط NMF، اطلاعات کافی برای تمایز کلاس‌های مختلف را حفظ کرده است.



۲-۴ پیشنهادات برای کارهای آتی

برای بهبود نتایج و گسترش این پژوهش، موارد زیر پیشنهاد می‌شود:

- استفاده از نسخه‌های پیشرفته‌تر NMF مانند Sparse NMF که با اعمال جریمه تنکی (Sparsity)، پایه‌هایی تمیزتر و تفکیک شده‌تر تولید می‌کند.
- اعمال الگوریتم بر روی داده‌های پیچیده‌تر مانند تصاویر چهره (مانند دیتاست Olivetti Faces) برای مشاهده دقیق‌تر قابلیت تجزیه اجزای صورت (چشم، بینی، لب).
- استفاده از روش‌های مقداردهی اولیه هوشمند به جای مقداردهی تصادفی برای افزایش سرعت همگرایی الگوریتم.



مراجع

- [1] Lee, D. D., & Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization. *Nature*, 401(6755), 788-791.
- [2] Aggarwal, C. C., & Reddy, C. K. (Eds.). (2013). *Data Clustering: Algorithms and Applications*. CRC Press.
- [3] LeCun, Y., Cortes, C., & Burges, C. J. (2010). MNIST handwritten digit database.
- [4] Hartigan, J. A., & Wong, M. A. (1979). Algorithm AS 136: A K-means clustering algorithm. *Applied Statistics*, 100-108.



پیوست

پروژه حاضر به زبان پایتون و با استفاده از کتابخانه‌های استاندارد داده‌کاوی پیاده‌سازی شده است. جهت مدیریت وابستگی‌ها و محیط مجازی از ابزار Poetry استفاده شده است.

دسترسی به کد منبع: نسخه کامل و قابل اجرای پروژه شامل فایل‌های پیکربندی (pyproject.toml) و تاریخچه تغییرات، در [مخزن گیت‌هاب](#) قابل دسترسی است.

در ادامه، کدهای اصلی فایل main.py برای بررسی منطق پیاده‌سازی آورده شده است:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import fetch_openml
from sklearn.decomposition import NMF
from sklearn.cluster import KMeans
from sklearn.metrics import accuracy_score, confusion_matrix
from scipy.optimize import linear_sum_assignment

def get_clustering_accuracy(y_true, y_pred):
    """
    Since clustering labels have no specific order (permutation invariance),
    this function finds the best match between cluster labels and true labels
    using the Hungarian algorithm, then calculates accuracy.
    """
    cm = confusion_matrix(y_true, y_pred)
    # Find the best assignment
    row_ind, col_ind = linear_sum_assignment(cm.max() - cm)
    return cm[row_ind, col_ind].sum() / np.sum(cm)

def plot_gallery(title, images, n_col=5, n_row=2):
    """Helper function to plot images (basis patterns or centroids)"""
    plt.figure(figsize=(2. * n_col, 2.26 * n_row))
    plt.suptitle(title, size=16)
    for i, comp in enumerate(images):
        plt.subplot(n_row, n_col, i + 1)
        vmax = max(comp.max(), -comp.min())
        plt.imshow(comp.reshape(28, 28), cmap=plt.cm.gray,
                   interpolation='nearest',
                   vmin=-vmax, vmax=vmax)
        plt.xticks(())
        plt.yticks(())
    plt.subplots_adjust(0.01, 0.05, 0.99, 0.93, 0.04, 0.)
```



```
# 1. Load MNIST Dataset
print("Loading MNIST dataset...")
mnist = fetch_openml('mnist_784', version=1, as_frame=False)
X = mnist.data
y = mnist.target.astype(int)

# Normalize data (NMF requires non-negative data)
# Pixel values are 0-255, scaling them to 0-1
X = X / 255.0

print(f"Data Matrix (X) shape: {X.shape}")

# 2. Run NMF Algorithm
# We use 10 components since there are 10 digits (0-9)
n_components = 10
print(f"Running NMF with {n_components} components on the full dataset...")

nmf = NMF(n_components=n_components, init='random',
           random_state=42, max_iter=500)

# W is the membership matrix (referred to as F in the project description)
W = nmf.fit_transform(X)

# H is the basis matrix (referred to as G in the project description)
# The rows of H contain the basis images
H = nmf.components_

print("NMF execution completed.")

# 3. Visualize the columns of Matrix G (Basis Images)
plot_gallery("NMF Basis Images (Columns of G)", H)
plt.show()

# 4. Clustering using Membership Matrix F (here W)
# Each data point belongs to the cluster corresponding to the highest weight in W
y_pred_nmf = np.argmax(W, axis=1)

# Calculate NMF clustering accuracy
acc_nmf = get_clustering_accuracy(y, y_pred_nmf)
print(f"\nNMF Clustering Accuracy: {acc_nmf:.4f}")

# 5. Compare with K-means
print("\nRunning K-means on the original data...")
kmeans = KMeans(n_clusters=n_components, random_state=42, n_init=10)
y_pred_kmeans = kmeans.fit_predict(X)

# Calculate K-means accuracy
acc_kmeans = get_clustering_accuracy(y, y_pred_kmeans)
print(f"K-means Clustering Accuracy: {acc_kmeans:.4f}")

# 6. Visualize K-means Centroids
plot_gallery("K-means Centroids", kmeans.cluster_centers_)
```



```
plt.show()

# Final Analysis
print("-" * 30)
print("Analysis of Results:")
if acc_nmf > acc_kmeans:
    print("In this run, NMF performed better than K-means.")
else:
    print("In this run, K-means performed better (or close) to NMF.")

print("Qualitative Difference:")
print("- NMF basis images typically show 'parts' of digits (strokes, loops).")
print("- K-means centroids show the 'average' of whole digits.")
```